



Классификация пассажиров Титаника: модель SVM

Практическое применение метода опорных векторов для предсказания выживаемости пассажиров на основе исторических данных

Постановка задачи классификации

Что такое классификация?

Задача машинного обучения с учителем, где модель определяет принадлежность объекта к одному из заранее известных классов на основе его признаков.

Целевая переменная

Survived — бинарный класс {0, 1}, где 1 означает выживание пассажира, 0 — гибель.

Датасет Titanic

Исторические данные о 891 пассажире легендарного лайнера с информацией о социальном статусе, возрасте, поле и других характеристиках.

Почему SVM?

- Строгая разделяющая гиперплоскость
- Эффективность на небольших выборках
- Устойчивость к переобучению

Описание признаков датасета

Исходные признаки

- **Age** — возраст пассажира
- **Sex** — пол
- **Pclass** — класс билета (1, 2, 3)
- **SibSp** — число братьев/сестер
- **Parch** — число родителей/детей
- **Fare** — стоимость билета
- **Embarked** — порт посадки

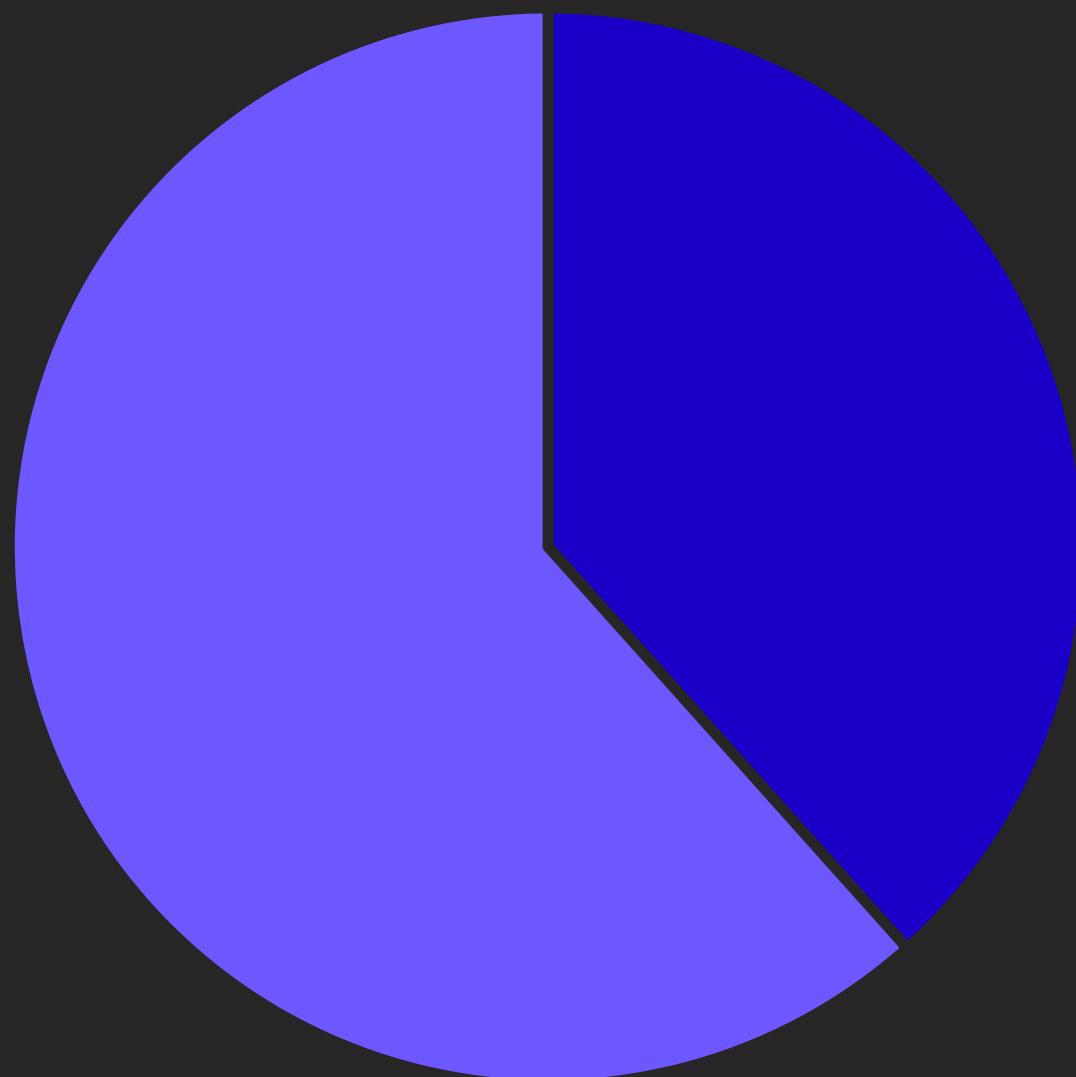
Удаленные признаки

Текстовые поля, не несущие структурированной информации:

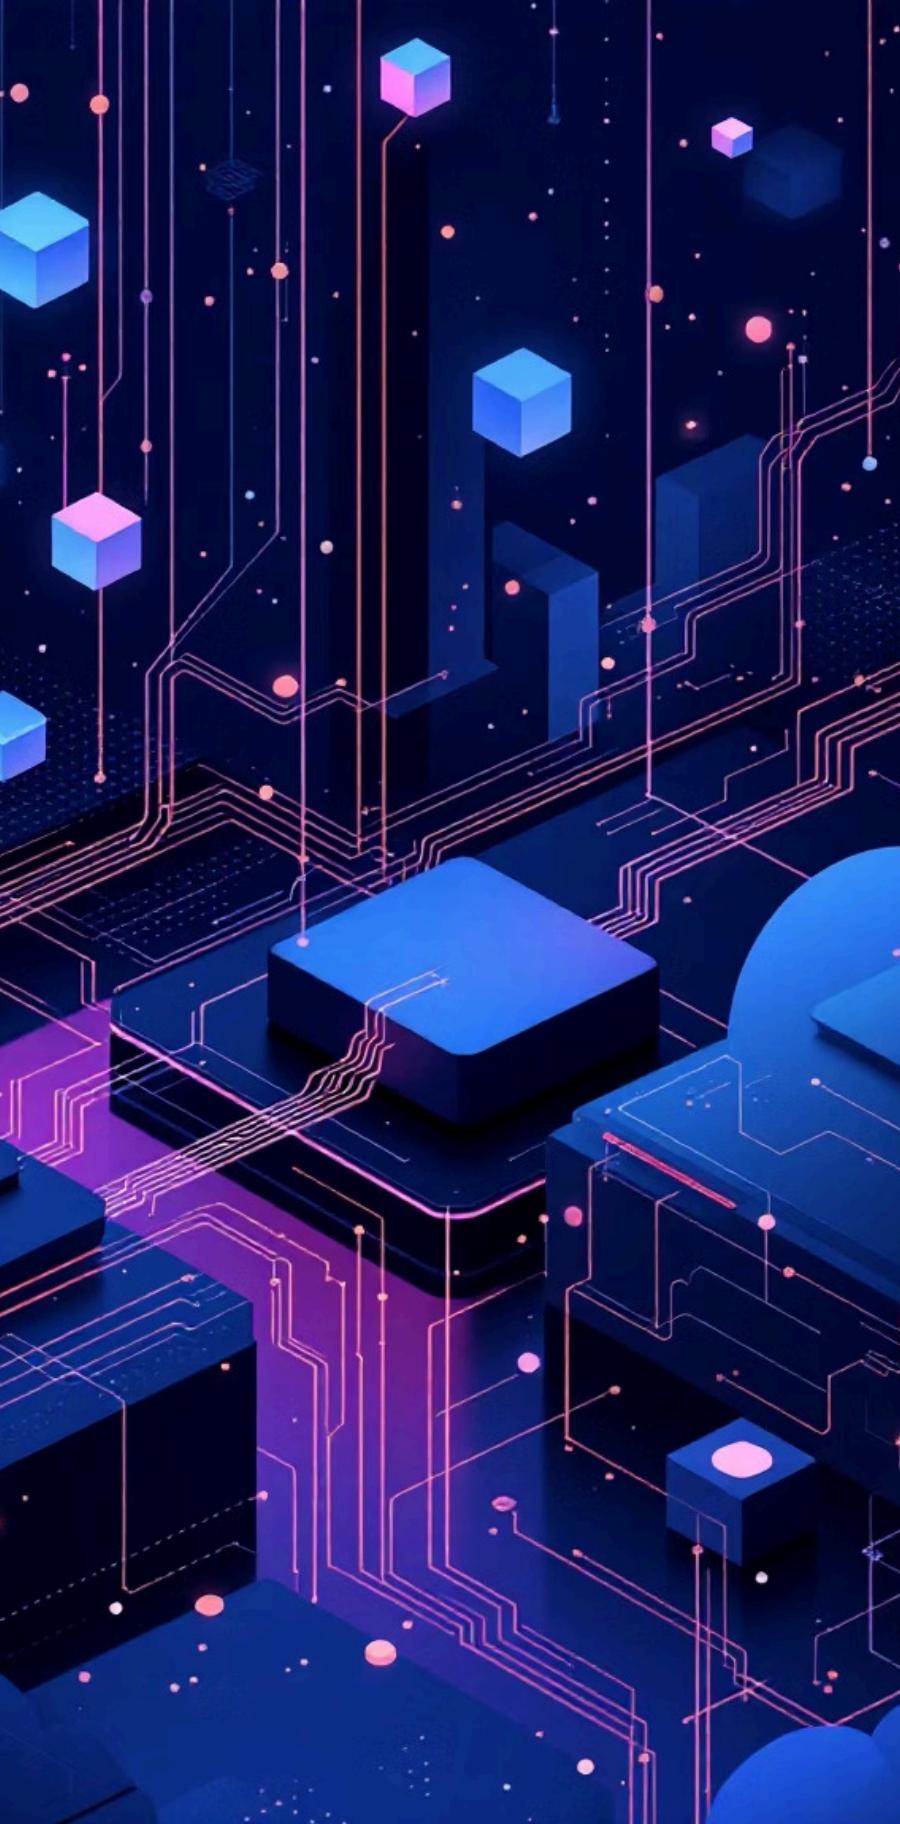
- **Name** — полное имя
- **Ticket** — номер билета
- **Cabin** — номер каюты (много пропусков)

Созданные признаки

- **FamilySize** — размер семьи
- **IsAlone** — путешествует один
- **Title** — обращение из имени
- **Deck** — палуба из Cabin



■ Выжили ■ Погибли



Предобработка данных

01

Обработка пропусков

Age — заполнение медианным значением по группам Pclass и Sex для сохранения демографических закономерностей.

Embarked — заполнение модой (наиболее частым портом посадки).

02

Кодирование категорий

OneHotEncoder для категориальных признаков: Sex, Embarked, Title.
Преобразование в бинарные векторы для корректной работы SVM.

03

Масштабирование

StandardScaler для числовых признаков: приведение к нулевому среднему и единичной дисперсии. Критично для SVM, чувствительного к масштабу.

04

Разделение выборки

Train/Test split 80/20 с **stratify** по целевой переменной для сохранения пропорций классов в обеих выборках.

Feature Engineering: создание новых признаков

1

FamilySize

$$\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$$

Общий размер семьи включая самого пассажира.

Гипотеза: большие семьи имели разные шансы на спасение.

2

IsAlone

$$\text{IsAlone} = (\text{FamilySize} == 1)$$

Бинарный признак одиночества. Одинокие путешественники могли действовать иначе в критической ситуации.

3

Title

Извлечение из Name: Mr, Mrs, Miss, Master, др.

Социальный статус и пол, влиявшие на приоритет эвакуации.

4

Age×Pclass

Интерактивный признак

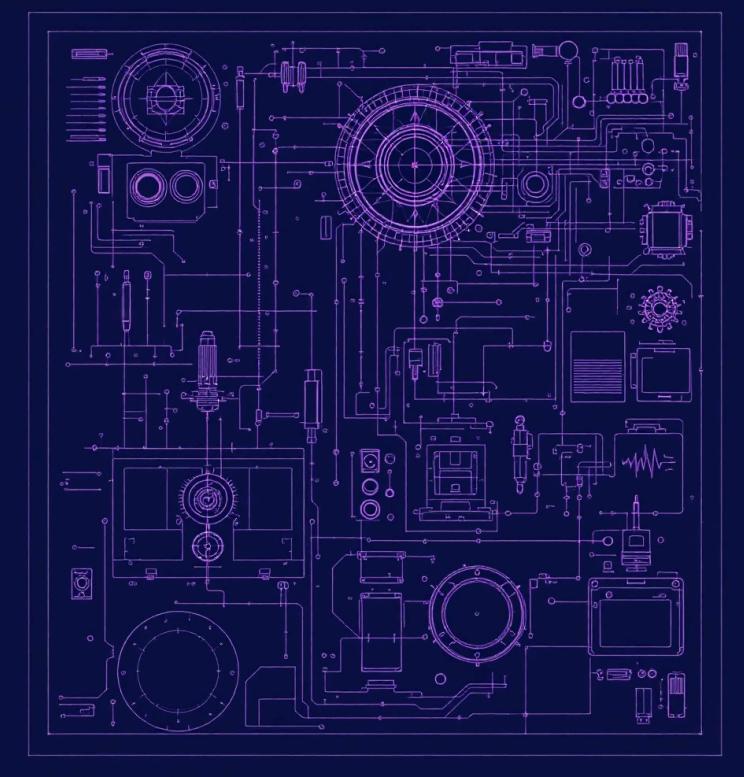
Взаимодействие возраста и класса билета для выявления нелинейных зависимостей.

5

FarePerPerson

$$\text{Fare} / \text{FamilySize}$$

Нормализованная стоимость на человека для корректного сравнения семей разного размера.



□ Почему это важно для SVM?

Метод опорных векторов чувствителен к информативности признаков. Создание новых комбинаций помогает модели находить более четкую разделяющую гиперплоскость между классами.

SVM: теоретические основы

Разделяющая гиперплоскость

SVM строит оптимальную линейную границу между классами в многомерном пространстве признаков, максимизируя расстояние до ближайших точек обоих классов.

Максимизация margin

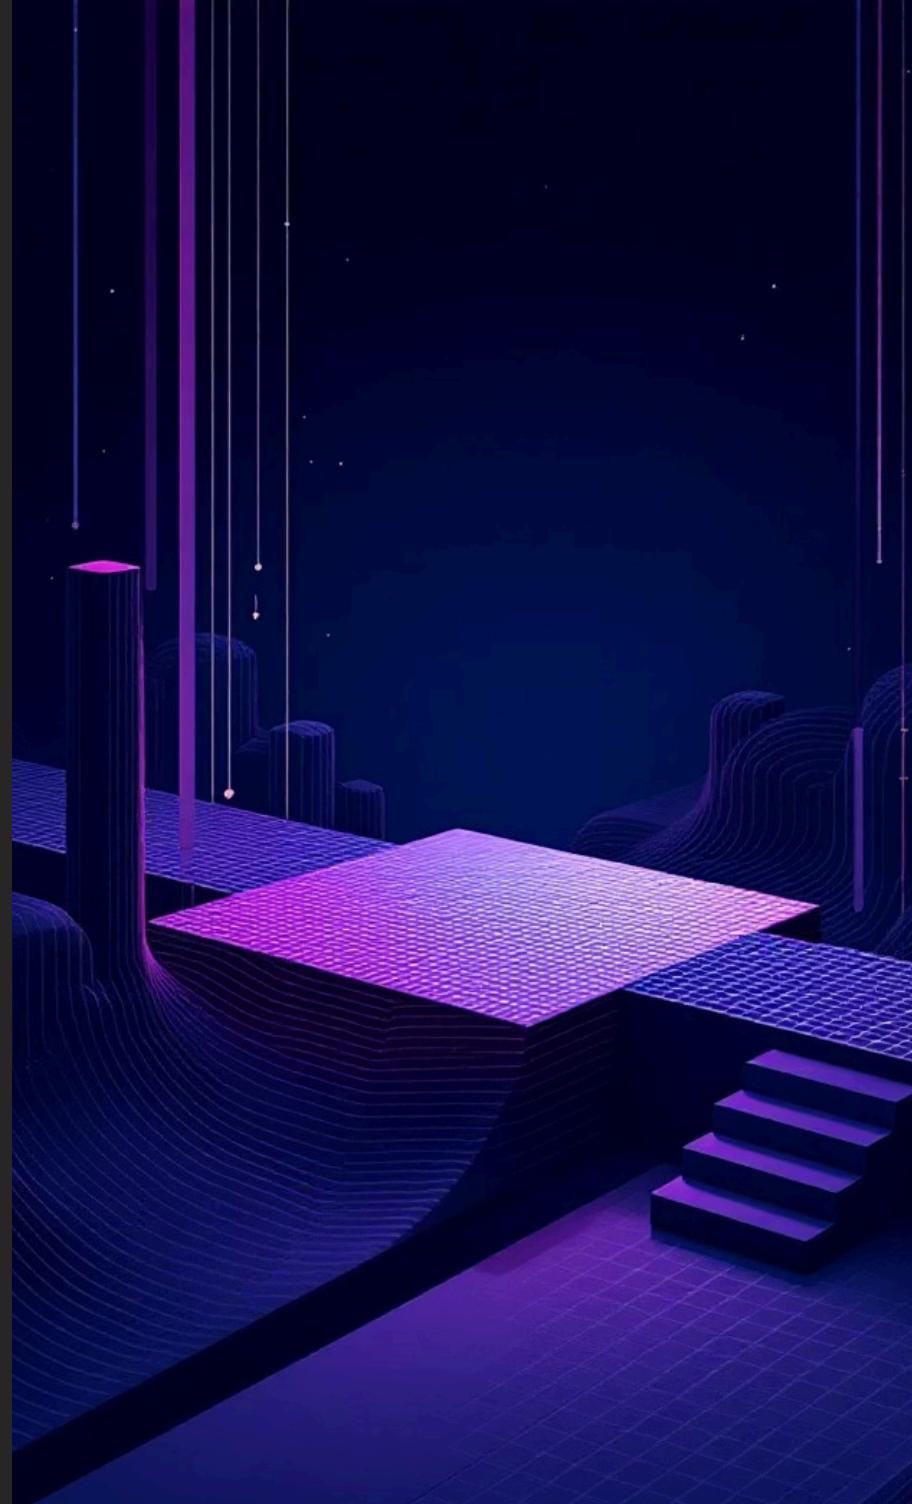
Ключевая идея: выбор такой гиперплоскости, которая максимально удалена от опорных векторов обоих классов. Это обеспечивает лучшую обобщающую способность модели.

Параметр C

Коэффициент штрафа за неправильную классификацию. Большое $C \rightarrow$ жесткая граница, малое $C \rightarrow$ более мягкая граница с допустимыми ошибками.

Функция ядра (kernel)

Преобразование исходного пространства в пространство более высокой размерности. **Linear** — для линейно разделимых данных, **RBF** — для сложных нелинейных зависимостей.



Настройка гиперпараметров SVM

Варьируемые параметры

Параметр C

Диапазон: [0.01, 0.1, 1, 10, 100]

Контролирует баланс между максимизацией margin и минимизацией ошибок классификации на обучающей выборке.

Тип ядра (kernel)

- **linear** — линейное разделение
- **rbf** — радиальная базисная функция
- **poly** — полиномиальное ядро

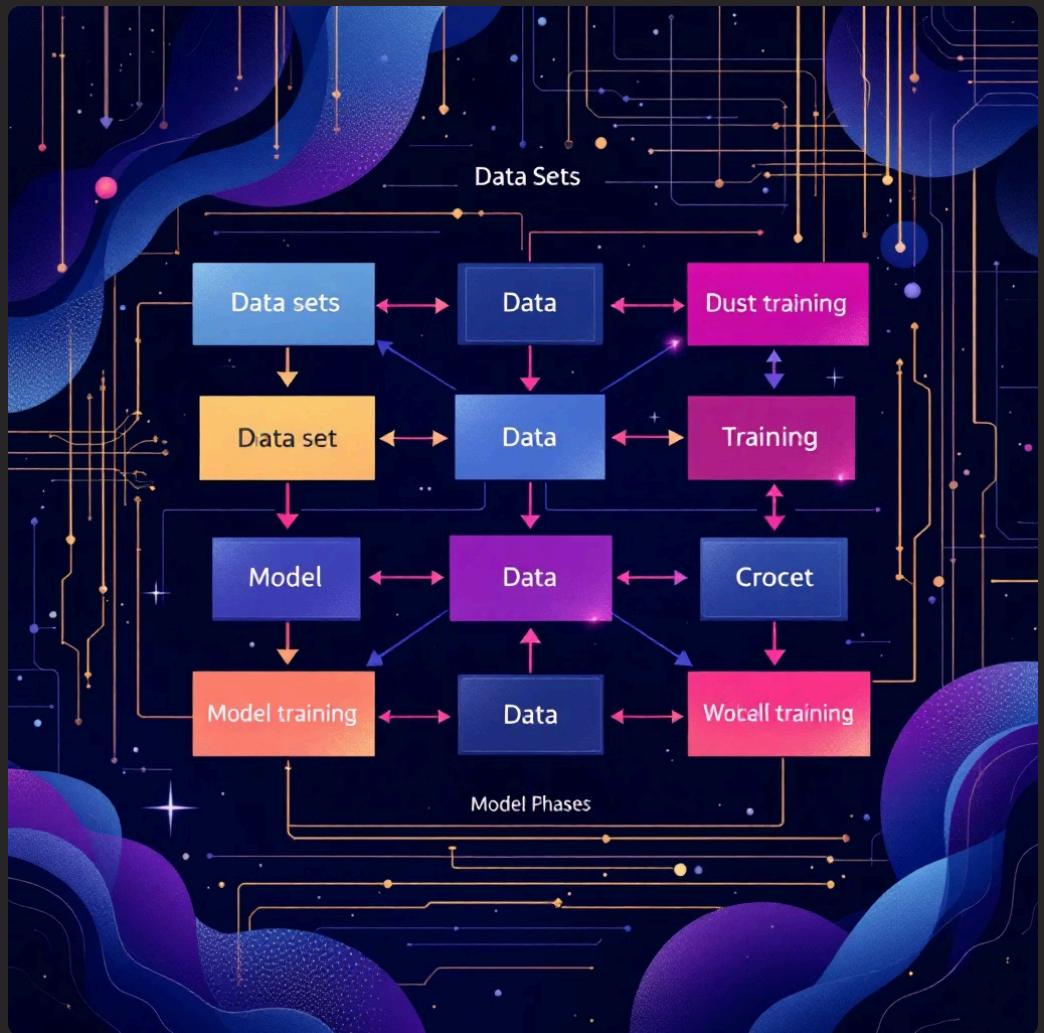
Параметр gamma

Диапазон: [0.001, 0.01, 0.1, 1]

Для RBF-ядра: определяет радиус влияния одного обучающего примера. Малое gamma → широкое влияние, большое → узкое.

Кросс-валидация

Применялся метод **5-fold cross-validation** для объективной оценки качества каждой комбинации параметров и предотвращения переобучения.



Сетка параметров перебиралась с помощью GridSearchCV для поиска оптимальной конфигурации по метрике F1-score.

Результаты модели SVM

Финальные метрики качества

83.2%

Accuracy

Общая точность
предсказаний на тестовой
выборке

81.7%

Precision

Доля корректно
предсказанных выживших
среди всех предсказанных
как выжившие

79.4%

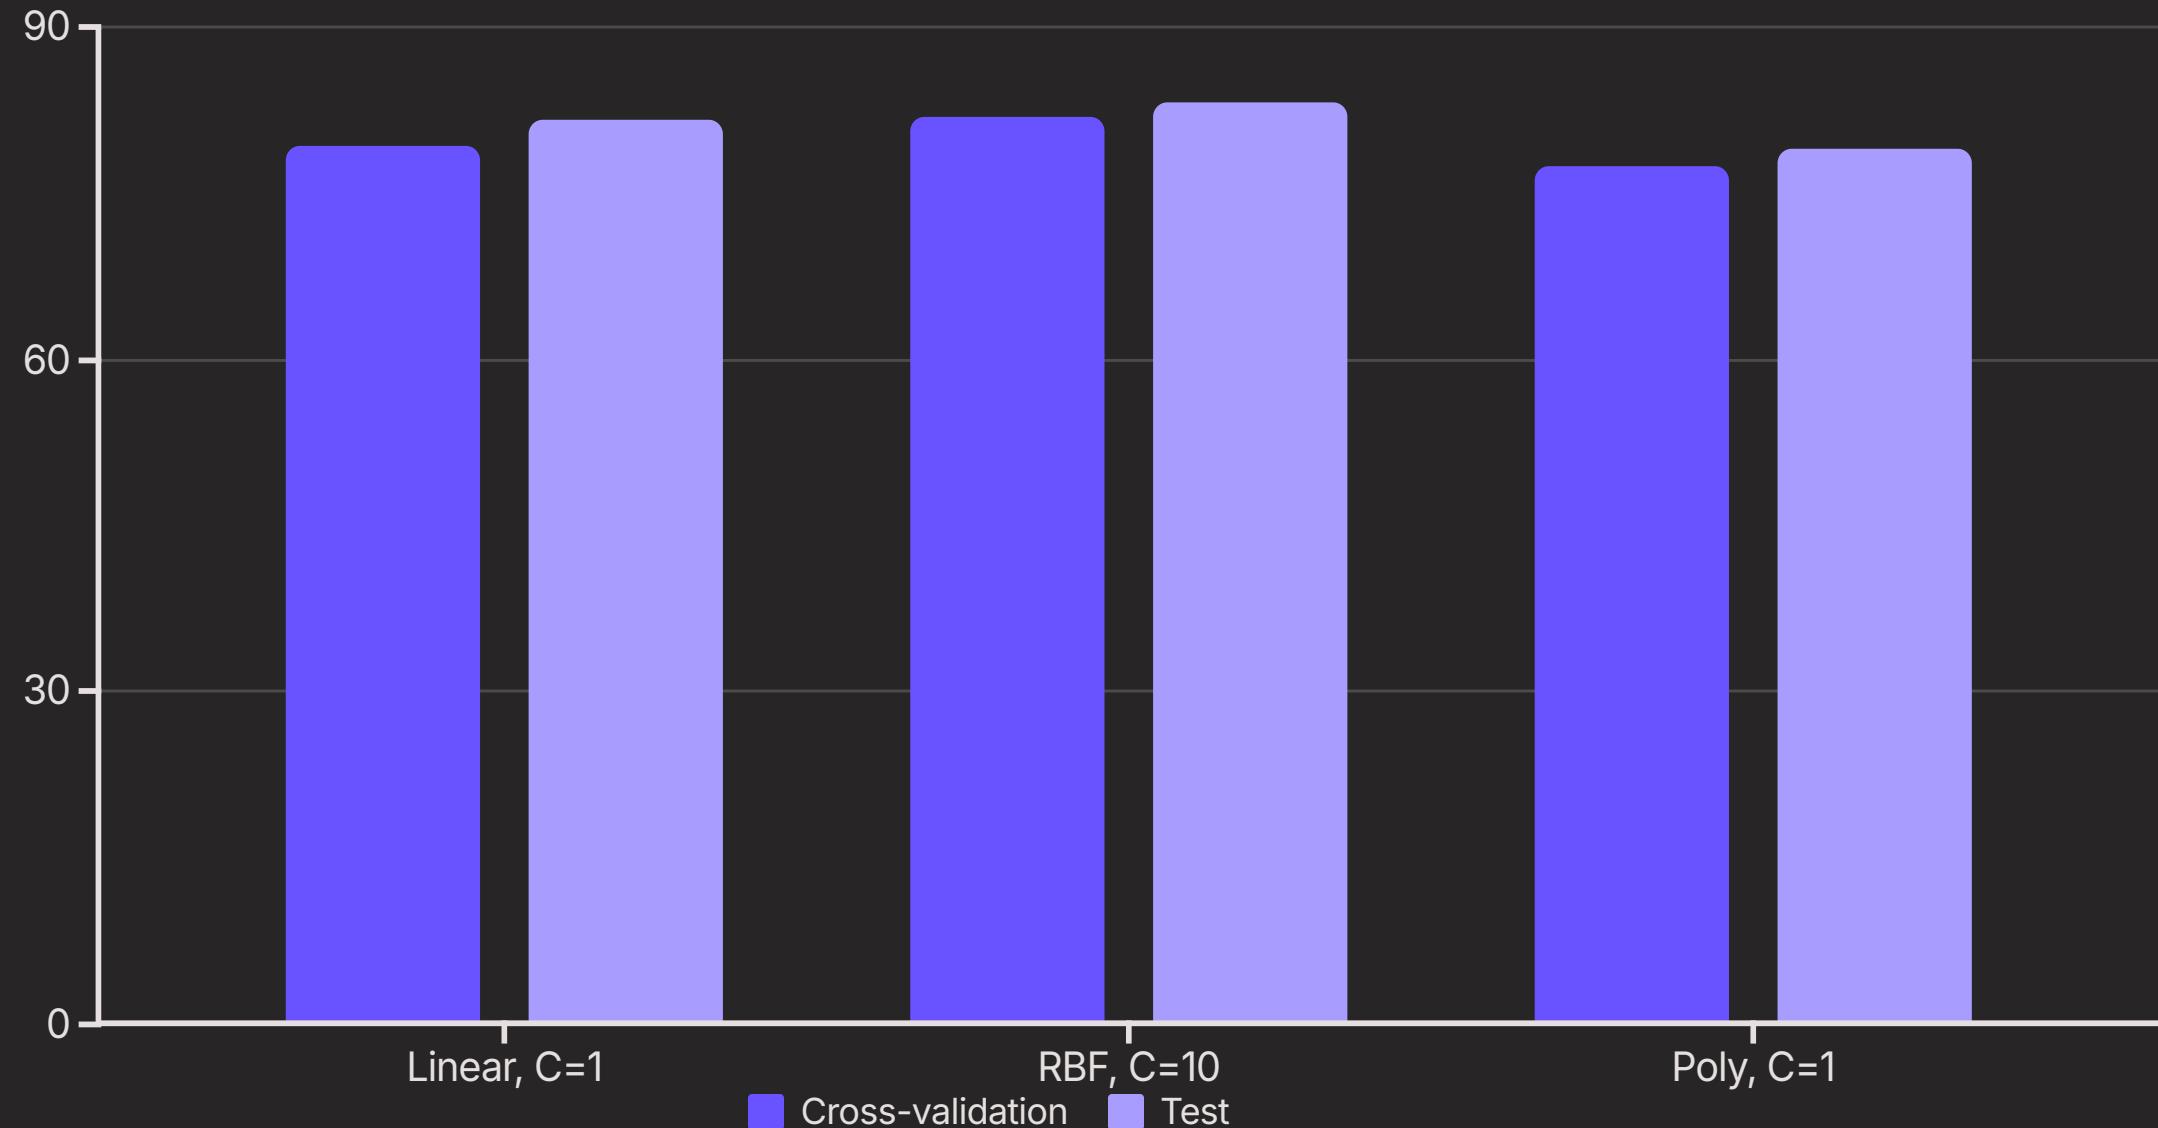
Recall

Доля найденных выживших
среди всех реально
выживших пассажиров

80.5%

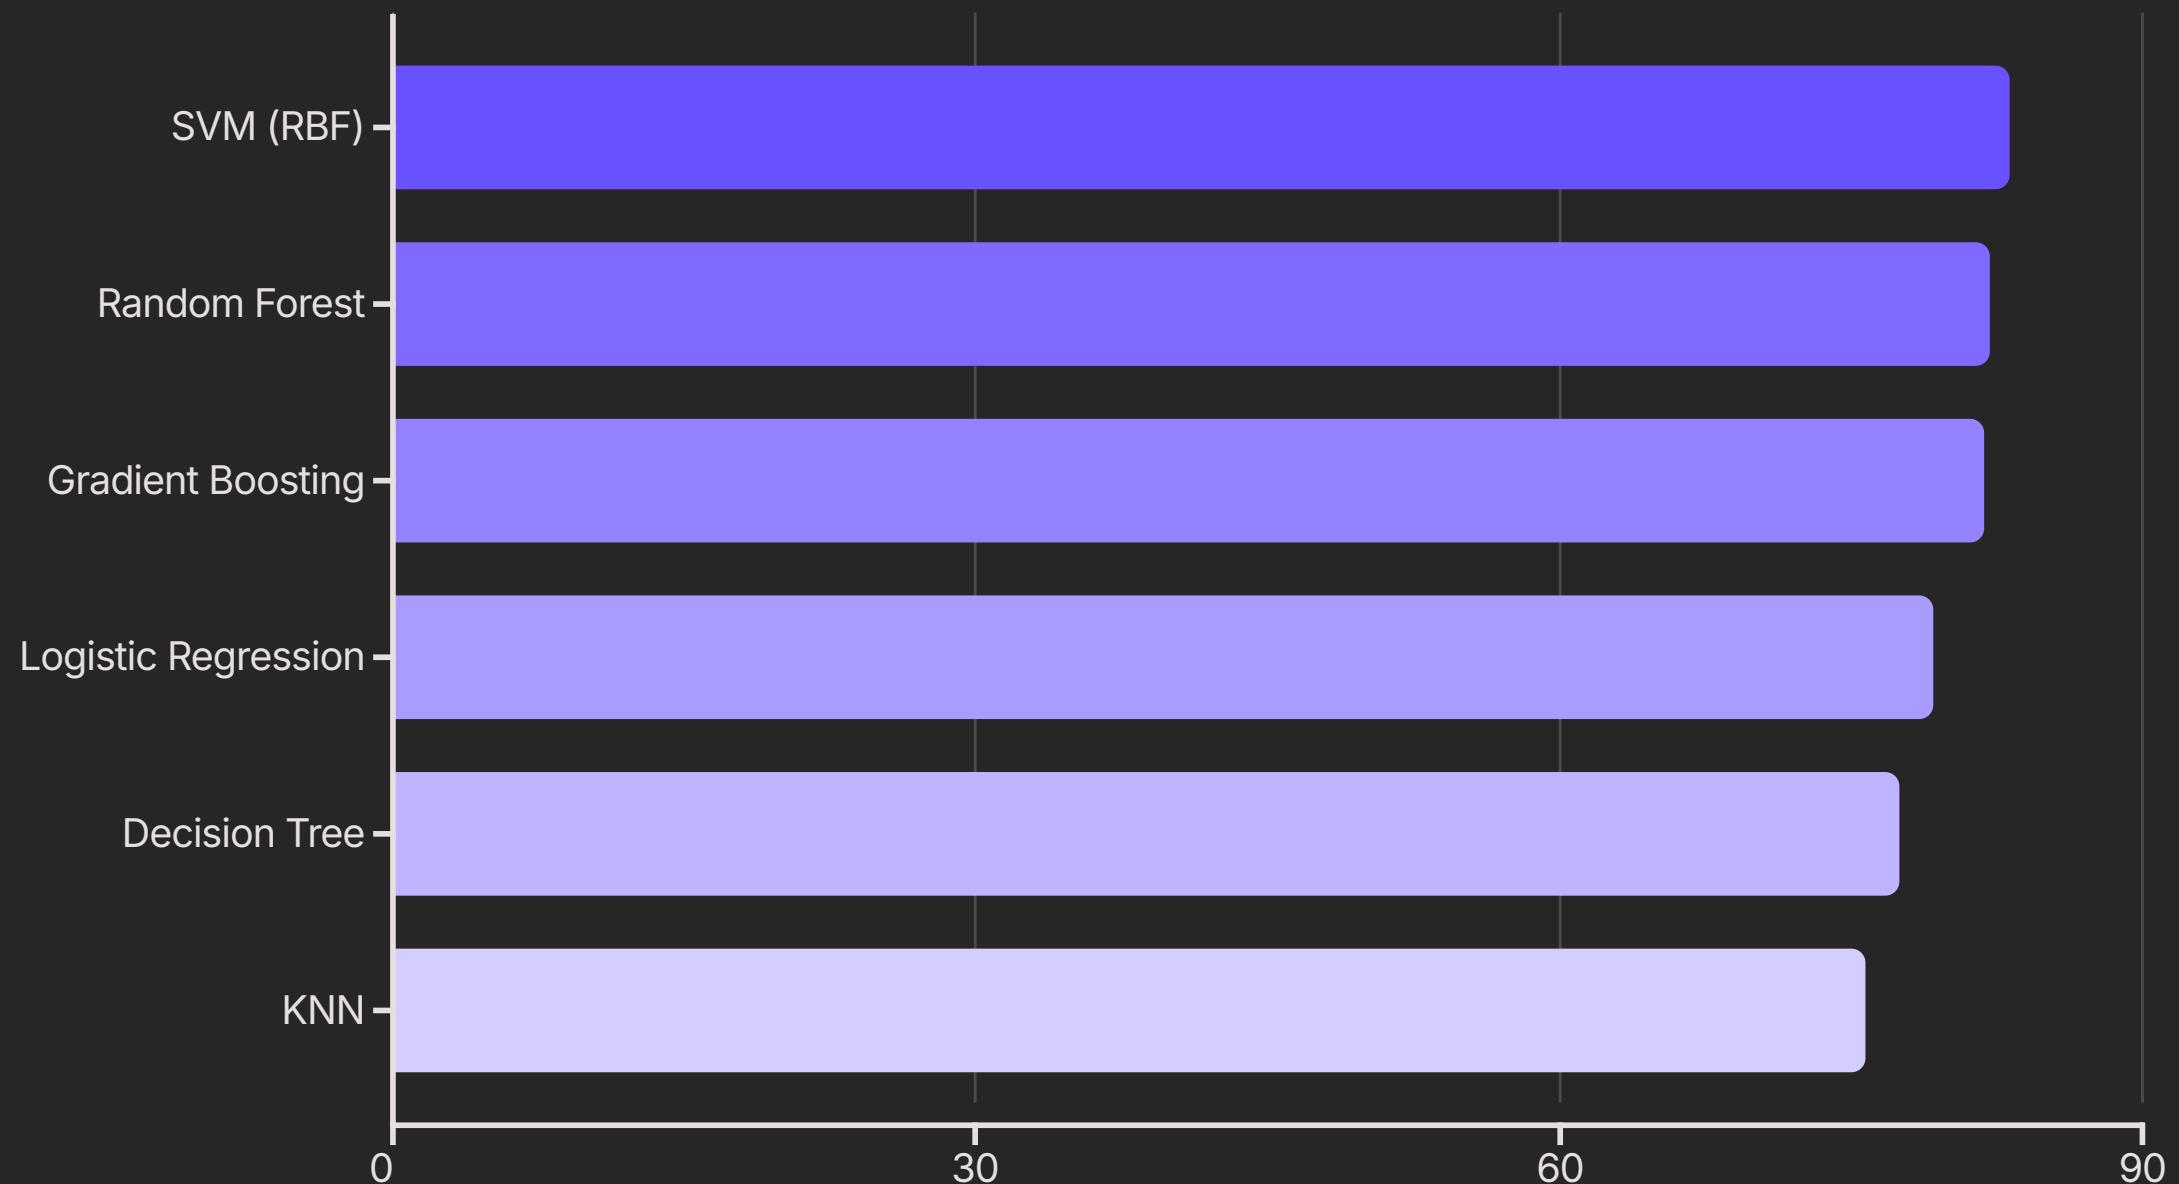
F1-score

Гармоническое среднее
между Precision и Recall



Лучшие результаты показала конфигурация с RBF-ядром и параметром C=10, демонстрирующая стабильность на кросс-валидации и тестовой выборке.

Сравнение SVM с другими моделями



Преимущества SVM

- Наивысшая точность среди протестированных моделей
- Стабильность результатов на кросс-валидации
- Устойчивость к переобучению при небольшом объеме данных
- Эффективная работа в пространстве высокой размерности

Наблюдения

Random Forest и Gradient Boosting показали сопоставимые результаты, но требовали больше времени на обучение. Логистическая регрессия уступает из-за предположения о линейности. KNN чувствителен к масштабу и зашумленности данных.

Выводы и перспективы развития

- **Ключевые достижения**

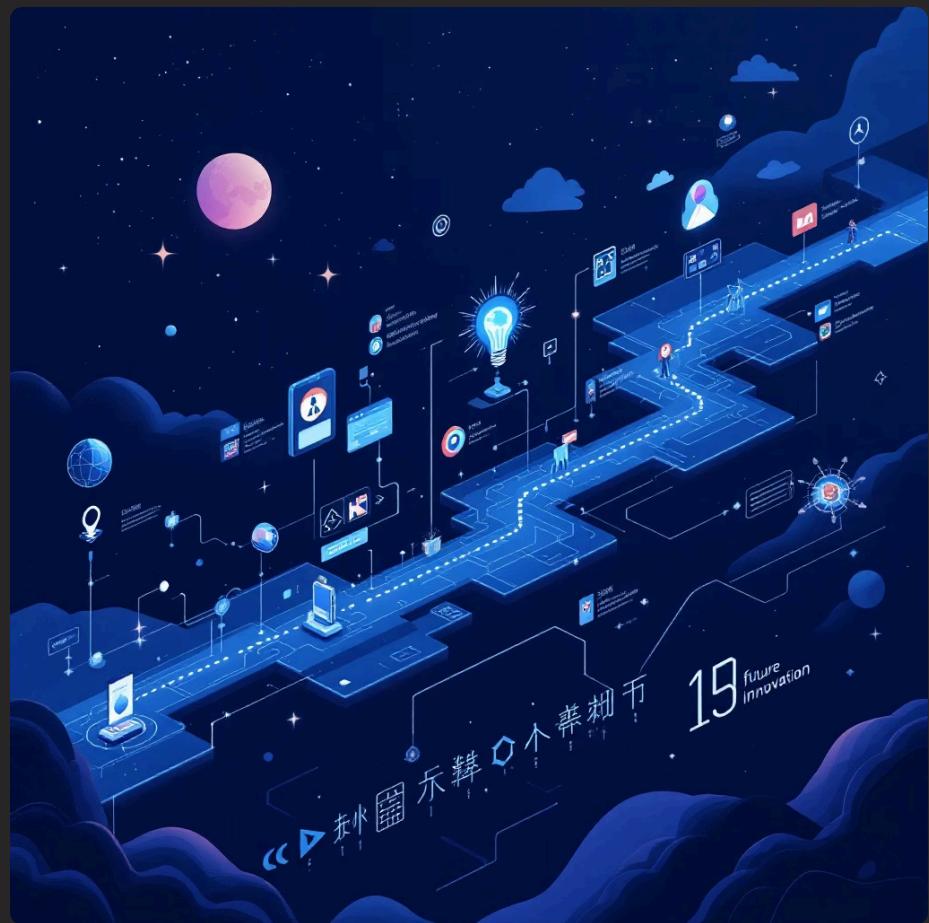
Модель SVM с RBF-ядром достигла **83.2% точности**, демонстрируя стабильные результаты и превосходя альтернативные алгоритмы на данной задаче.

- **Критические преобразования**

Нормализация данных, OneHotEncoding категориальных признаков и создание новых признаков (Title, FamilySize, IsAlone) существенно улучшили качество модели.

- **Устойчивость к малым данным**

SVM показал эффективность на относительно небольшой выборке благодаря механизму максимизации margin и опорным векторам.



Направления для улучшения



Оптимизация ядер

Тестирование кастомных функций ядра и более детальная настройка параметров гамма



Новые признаки

Извлечение информации из каюты, анализ взаимодействий между признаками высших порядков



Ансамбли

Комбинирование SVM с другими моделями для повышения обобщающей способности



Deep Learning

Сравнение с нейронными сетями при расширении датасета